

# 卷积神经网络在局部放电图像模式识别中的应用

万晓琪, 宋辉, 罗林根, 李喆, 盛戈皞, 江秀臣

(上海交通大学 电气工程系, 上海市 闵行区 200240)

## Application of Convolutional Neural Networks in Pattern Recognition of Partial Discharge Image

WAN Xiaoqi, SONG Hui, LUO Lingen, LI Zhe, SHENG Gehao, JIANG Xiuchen

(Department of Electrical Engineering, Shanghai Jiao Tong University, Minhang District, Shanghai 200240, China)

**ABSTRACT:** With established big data platforms, a large number of unstructured on-site data such as images are accumulated in data centers. Traditional partial discharge pattern recognition method is generally aimed at structured data and can not be directly applied to unstructured data. To solve this problem, a time-domain waveform pattern recognition method based on one-dimensional convolutional neural network is proposed. The image processing technology is used to preprocess the input images and one-dimensional characteristics of the waveform are obtained. Then the linearized function is used to normalize the data. Based on deep learning, the network is used for pattern recognition directly. Through on-site detection and lab simulated experiments, image data sets for five partial discharge defects are established and comparative experiments are conducted. Experimental results show that the recognition rate of partial discharges using one-dimensional convolutional neural network is 88.9%, significantly higher than that of support vector machine and back propagation neural network model. It also performs better than two-dimensional convolutional neural network under the same time complexity. The method autonomously learns features through the network and does not need to manually extract features. In conclusion, it has advantages of lower experimental complexity, higher recognition rate and better robustness.

**KEY WORDS:** convolutional neural network (CNN); partial discharge; image; pattern recognition

**摘要:** 随着大数据平台的建立, 数据中心积累了大量现场检测存储的图像等非结构化数据。传统的局部放电模式识别方法一般针对结构化数据, 无法直接应用于非结构化数据。为解决该问题, 提出一种基于一维卷积神经网络的局部放电时

域波形图像的模式识别方法。利用图像处理技术对输入图像进行预处理, 获取数据一维特性并进行线性归一化。基于深度学习, 利用网络直接进行模式识别。通过变电站现场带电检测和实验室模拟实验, 建立了5种局放缺陷类型的时域波形图像数据集, 并进行了对比实验。实验结果表明, 使用一维卷积神经网络对局放缺陷进行模式识别的正确率为88.9%, 显著优于支持向量机、反向传播神经网络模型, 且在相同时间复杂度情况下优于二维卷积神经网络。该方法通过网络自主学习特征, 无需人工提取, 实现了对时域波形图像类非结构化数据的直接识别, 实验复杂度低, 具有更高识别率和更好鲁棒性。

**关键词:** 卷积神经网络; 局部放电; 图像; 模式识别

**DOI:** 10.13335/j.1000-3673.pst.2018.1345

## 0 引言

气体绝缘组合电器(gas insulated switchgear, GIS)作为电力系统的主要设备, 其可靠性对电网的稳定运行有重要影响。绝缘劣化是造成设备故障的主要原因, 对GIS设备进行局部放电检测、分类和定位是绝缘性能评估的3个阶段<sup>[1]</sup>。传统的局部放电模式识别步骤包括: 构造局部放电模式、对信号进行特征提取、选择模式识别算法<sup>[2]</sup>。

当前国内外对局部放电模式识别的研究主要包括: 对不同局放检测方法得到的数据进行特征量提取, 以及不同模式识别算法的构建<sup>[3]</sup>。文献[4]采用小波包树能量矩阵奇异值分解的方式, 从频率信息提取特征。文献[5]基于多分辨高阶奇异谱熵分析提升重构参数鲁棒性与维数特征表征能力。文献[6]采用稀疏分解模式识别方法对统计特征参数进行识别。文献[7]利用支持向量机对三维图谱混沌特征进行分类。上述文献均针对放电模式、二维或三维图谱图所提取的结构化数据进行缺陷分类。

随着局放带电检测技术的推广应用, 变电站现

**基金项目:** 国家重点研发计划项目(2017YFB0902705); 国家电网公司科技项目。

Project Supported by: National Key Research and Development Program of China (2017YFB0902705), Science and Technology Project of State Grid Corporation of China.



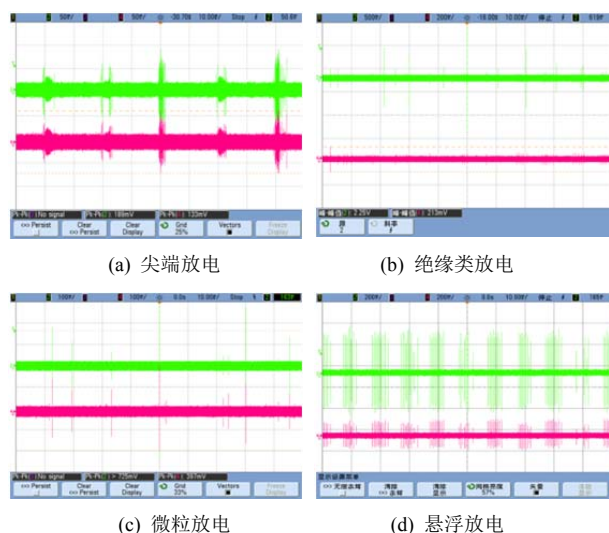


图4 部分现场局部放电检测的时域波形图像

Fig. 4 Time-domain waveform of GIS partial discharge detection

## 2 基于一维卷积神经网络的局放图像模式识别

### 2.1 数据预处理

示波器直接存储导出各类局放时域波形图像, 本文采用图像处理技术对输入图像进行预处理, 进一步表达特征。具体操作包括图像分割、图像灰度化、图像二值化、图像增强等<sup>[8]</sup>。

用二维数组表示原始图像, 对图像进行分割, 提取得到  $1000 \times 636$  的局放时域波形图像。采用分量法对彩色图像进行灰度化处理, 分别得到 R、G、B 3 个通道的灰度图像。图像灰度化表达式为

$$f_1(i, j) = R(i, j); f_2(i, j) = G(i, j); f_3(i, j) = B(i, j) \quad (1)$$

式中  $f_k(i, j) (k=1, 2, 3)$  为转换后的灰度图像在  $(i, j)$  处的灰度值。

根据示波器显示的通道色彩不同, 利用灰度差距进行区分, 选择局部放电通道。阈值  $T$  为 60, 使用公式对 R 通道灰度图进行全局二值化操作, 提取通道 2 部分。具体表达式为

$$g(x, y) = \begin{cases} 0, & f(x, y) < T \\ 1, & f(x, y) \geq T \end{cases} \quad (2)$$

由于样本数据较少, 不同缺陷类型的数据集不平衡, 训练过程将出现过拟合。为增强网络泛化能力, 本文进行了数据增强。对不同样本数量的时域波形图像, 选择不同滑动步长剪裁图像, 扩充数据。

图像预处理得到只含脉冲电压的图像, 保存数据形式为二维矩阵。以某一悬浮缺陷类型为例, 选择滑动步长为 10, 将图像扩充为 2 张子图像作为新样本集, 图 5 为图像预处理具体情况。

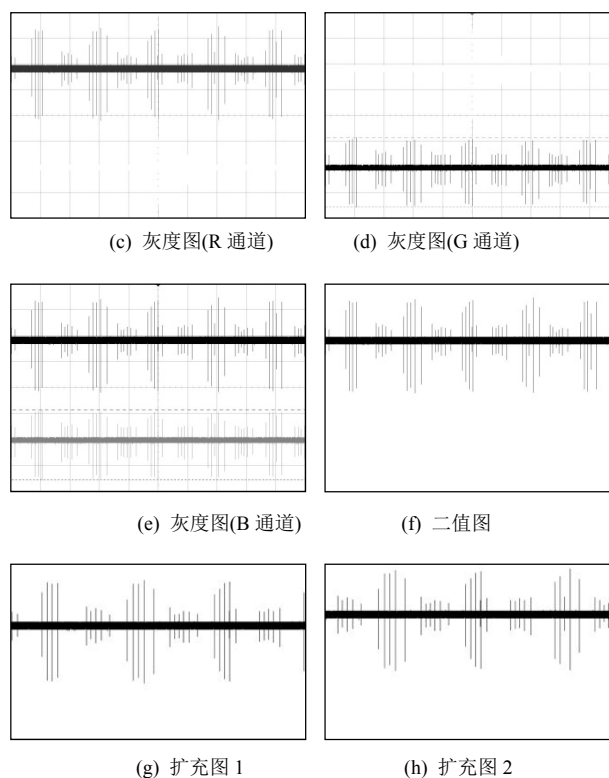



图5 时域波形图像预处理

Fig. 5 Time-domain waveform image preprocessing

### 2.2 网络模型

#### 2.2.1 卷积神经网络

深度学习(deep learning, DL)具有特征提取、数据降维等特点, 能够从样本数据中自主学习得到特征表达<sup>[9-11]</sup>。对于深度学习分类模型, 卷积神经网络(convolutional neural networks, CNN)由于对数据具有位移、缩放、扭曲等高度不变性, 更利于图像数据处理<sup>[12]</sup>。

卷积神经网络基本结构包括: 输入层、卷积层、下采样层、连接层、输出层。通过使用卷积滤波器



对图像进行卷积的计算公式如下:

$$y_j^l = f(b_j^l + \sum_{i=1}^k F_{\text{conv2D}}(y_i^{l-1}, \omega_{ij}^{l-1})) \quad (3)$$

式中:  $f(\cdot)$  表示激励函数;  $F_{\text{conv2D}}$  表示二维卷积公式;  $b_j$  表示偏置值;  $\omega_{ij}$  表示神经元间的权重;  $y_j$  表示第  $j$  个神经元输入。

卷积层后加入池化层(pooling), 用于对特征图进行子采样(subsampling), 计算公式为:

$$y_j^l = \beta_j^l S_{\text{down}}(y_j^{l-1}) + b_j^l \quad (4)$$

式中  $S_{\text{down}}(\cdot)$  表示下采样函数。

通过合并池化, 降低图像特征的维数与模型计算量<sup>[13]</sup>。网络结构中的全连接层用于整合局部信息, 最后使用分类器进行分类。

### 2.2.2 一维卷积神经网络

对于语音信号、电压波形等数据, 2 个维度分别表示时间信息、特征参数。为更好利用时域波形的一维特性, 并降低网络模型的复杂度, 本文采用一维卷积神经网络。

一维卷积神经网络与传统的二维卷积神经网络区别在于前者的卷积核和特征映射为一维向量。一维卷积和反向操作替代二维卷积和横向旋转等矩阵操作<sup>[14]</sup>。在一维卷积神经网络中, 卷积计算公式(记  $F_{\text{conv1D}}$ )为:

$$y_j^l = f(b_j^l + \sum_{i=1}^k F_{\text{conv1D}}(y_i^{l-1}, \omega_{ij}^{l-1})) \quad (5)$$

为适应时域波形一维特性, 基于其工程含义, 本文将预处理得到的二维矩阵列向求和, 得到一维数组, 用于表示局放脉冲电压幅值信息。对一维数组进行线性归一化, 转换函数为

$$x^* = \frac{x - x_1}{x_2 - x_1} \quad (6)$$

式中:  $x_1$  表示样本数据最小值;  $x_2$  表示样本数据最大值。

### 2.2.3 网络训练

卷积神经网络训练包括前向传播阶段和反向传播阶段。网络经过前向传播阶段的输出表达为

$$O_p = F_n(\dots F_2(F_1(X_p W^{(1)}) W^{(2)}) \dots W^{(N)}) \quad (7)$$

式中:  $W$  为网络各层的参数;  $X$  为输入数据;  $F$  为激活函数<sup>[15]</sup>。

反向传播阶段中, 使用反向传播算法计算实际输出与期望输出误差, 利用梯度下降法更新并优化网络各个参数, 最小化误差<sup>[16]</sup>。网络模型中权重与偏置量的更新计算方法由式(8)(9)给出。

$$\omega_{ij}^{l-1}(t+1) = \omega_{ij}^{l-1}(t) - \eta \frac{\partial J}{\partial \omega_{ij}^{l-1}} \quad (8)$$

$$b_j^l(t+1) = b_j^l(t) - \eta \frac{\partial J}{\partial b_j^l} \quad (9)$$

式中:  $\eta$  表示学习率;  $J$  表示代价函数。

经过正则化的代价函数表达式如下:

$$J(\theta) = -\frac{1}{m} \left[ \sum_{i=1}^m \sum_{j=1}^k 1\{y^{(i)} = j\} \log \frac{e^{\theta_j^T x^{(i)}}}{\sum_{l=1}^k e^{\theta_l^T x^{(i)}}} \right] + \frac{\lambda}{2} \sum_{i=1}^m \sum_{j=0}^n \theta_{ij}^2 \quad (10)$$

式中  $1\{\cdot\}$  表示指示性函数, 当括号内表达式值为真时, 该函数取值 1; 表达式为假时, 该函数取值 0。

### 2.3 模式识别流程

对 GIS 设备局部放电时域波形图像进行模式识别的具体流程框图如图 6 所示。

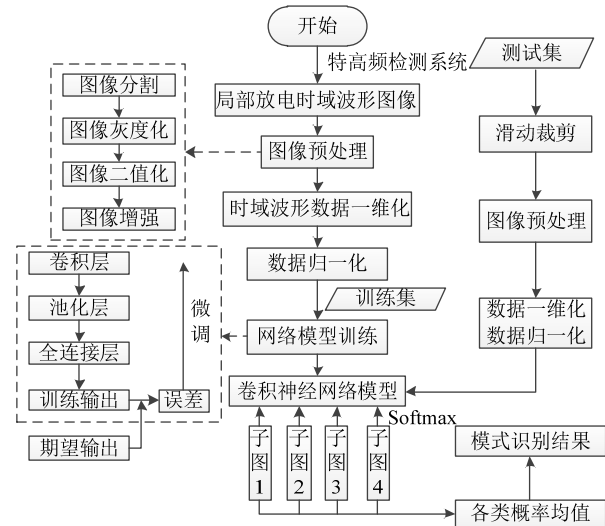


图 6 基于一维卷积神经网络的局放图像模式识别流程  
Fig. 6 Process diagram of partial discharge image pattern recognition by 1-D CNN

具体步骤如下:

1) 对局放时域波形图像数据进行预处理, 将一维数组进行归一化, 作为输入数据。

2) 利用构建的一维卷积神经网络模型, 对训练集进行学习训练。

3) 采用交叉熵代价函数, 利用随机梯度下降法更新模型参数。通过反向传播算法进行有监督微调, 优化模型。

4) 选择步长为 10 对原始测试图像进行滑动裁剪, 生成 4 张子图像。对子图像分别预处理并归一化, 输入网络模型, 使用 Softmax 分类器得到各类概率值, 利用投票法, 即取 4 张子图像概率均值, 最大概率为该测试图像缺陷分类。

### 3 识别结果与对比分析

本文采用基于深度学习的一维卷积神经网络

结构,利用 TensorFlow 深度学习框架,Python 语言搭建了网络模型。识别平台为 2.5GHz i5 处理器,内存为 16 G。基于 GIS 特高频带电检测得到的时域波形图像,进行模式识别。识别目标包括悬浮电位、绝缘类放电、尖端电晕、微粒放电以及干扰。

3.1 网络结构设置

针对不同的任务,网络结构的确定需要结合理论分析与实验观察,选择合适的参数<sup>[17]</sup>。本文讨论了 5 种网络结构深度,其中 5 种网络分别含有 1~5 个卷积层与对应的池化层,表 1 表示了 5 种网络结构与对应的分类性能,每种网络卷积核尺寸均为 1×13,池化核尺寸均为 1×2。

表 1 不同网络深度的模式识别结果				
Tab. 1 Pattern recognition under different network depths				
模型	卷积层层数	池化层层数	深度	识别率/%
1	1	1	5	76.94
2	2	2	7	80.83
3	3	3	9	81.94
4	4	4	11	86.94
5	5	5	13	87.78

实验中控制卷积核大小、池化核大小与其他参数不变,仅增加卷积层和池化层的层数。实验结果表明,梯度消失前增加网络的深度,将提升网络性能。由于输入图像尺寸的限制与实验平台的性能限制,最终的网络模型含有 5 个卷积层和 5 个池化层。

对每种深度分别设置 6 个不同的 CNN 网络模型,6 种模型中卷积核尺寸不同,其他参数均相同。表 2 表示了深度为 11 的网络在不同卷积核尺寸下的分类性能,该网络含有 4 个卷积层与 4 个池化层。

表 2 不同卷积核尺寸的模式识别结果(深度为 11)			
Tab. 2 Pattern recognition under different convolutional kernel sizes (11 depth)			
模型	卷积层尺寸	池化层尺寸	识别率/%
1	1×5	1×2	84.44
2	1×7	1×2	83.06
3	1×9	1×2	85.00
4	1×11	1×2	85.83
5	1×13	1×2	86.94
6	1×15	1×2	82.78

由实验结果可以看出,对于网络深度为 11 的模型,卷积核尺寸变大,网络识别率先减小后增加再减小。卷积核尺寸过大将丢失原始图像特征,过小将增加网络复杂度,降低运算速度。针对本文的输入图像,通过实验最终确定了合适的卷积核尺寸。

针对每种深度,本文还设置了 3 个仅池化核尺寸不同的 CNN 模型,通过实验最终选择池化核尺寸为 1×2。网络特征通道数过少,可能丢失利于网

络学习的特征;过多将增加网络复杂度和训练时间。本文对每种深度设置了 4 种仅特征通道数不同的网络,通过实验并观察训练模型的性能,最终确定了网络的特征通道数<sup>[18]</sup>。

图 7 为本文最终采用的卷积神经网络模型结构图,一共 13 层,包括 1 个输入层、5 个卷积层、5 个池化层、1 个全连接层和 1 个输出分类层。

输入层是处理得到的统一尺寸为 1×784 的时域波形数据。输出层选用适应于非线性多分类问题的 Softmax 分类器。网络输出采用 one-hot 编码方式。

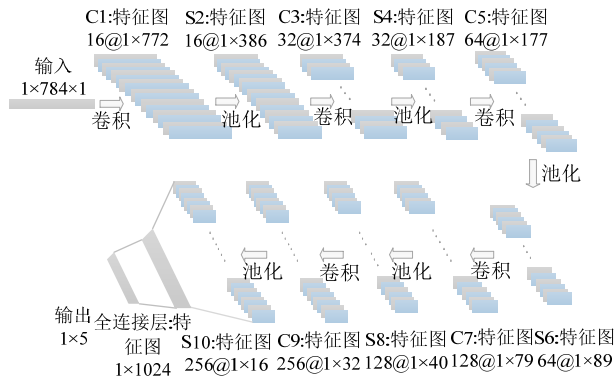


图 7 一维卷积神经网络模型结构  
Fig. 7 Structure of one-dimensional convolutional neural network model

ReLU 函数输出不会随输入的增加而趋于饱和,且能加快收敛速度<sup>[19]</sup>。因此本文采用不饱和和非线性函数 ReLU 函数作为激励函数。函数表达式为  $f(x) = \max(0, x)$  (11)

最大池化更适于分离稀疏的特征<sup>[20]</sup>。局放时域波形特征较为稀疏,更适合最大池化。本文通过实验比较最大池化、均值池化、随机池化 3 种方法,结果表明采用能得到更高识别率,因此池化层采用最大池化方法。卷积层步长为 1,池化层步长为 2,对应参数设置见表 3。

3.2 实验结果与分析

通过滑动裁剪将原数据扩充得到 1800 张图像作为样本集。以尖端电晕缺陷类型为例,选择步长

表 3 一维卷积神经网络结构设置				
Tab. 3 Structure setting of one-dimensional convolutional neural network				
结构层	卷积层核尺寸	池化层核尺寸	通道数	输出大小
输入层			1	1×784×1
卷积层 1 池化层 1	1×13	1×2	16	1×386×16
卷积层 2 池化层 2	1×13	1×2	32	1×187×32
卷积层 3 池化层 3	1×11	1×2	64	1×89×64
卷积层 4 池化层 4	1×11	1×2	128	1×40×128
卷积层 5 池化层 5	1×9	1×2	256	1×16×256
全连接层				1×1024
输出层				1×5

为 20 将 1 张图像扩充为 4 张, 成为新数据集。实验对其中 1440 张图像采用 5 倍交叉验证法, 得到模型参数, 测试集为 360 张图像。为更好判断网络工程应用能力, 4 种缺陷类型数据集 70% 来自变电站现场检测, 30% 来自模拟实验。各种放电模型与现场放电类型对应, 如气隙放电缺陷模型对应于 GIS 绝缘子内部存在气隙或绝缘子与导体接触面存在气隙的情况。干扰类型数据集均来自现场带电检测。其中相同缺陷的数据集中, 50% 来自同一设备在相同测试位置不同放电时间搜集得到的局部放电时域波形图像, 50% 来自不同设备。

一维卷积神经网络相关参数设置如下: 迭代次数 24 000 次, 学习速率 0.005, 网络训练方式为小量样本训练。表 4 为模式识别得到的混淆矩阵。

表 4 一维卷积神经网络局部放电模式识别混淆矩阵 Tab. 4 Confusion matrix of partial discharge pattern recognition by 1-D CNN %					
混淆情况	输出电晕	输出干扰	输出绝缘类	输出微粒	输出悬浮
尖端电晕	100	0	0	0	0
干扰	0	95.8	0	0	4.2
绝缘类放电	0	8	85	4	3
微粒放电	0	10	70	20	0
悬浮电位	0	8	4	0	88

实验一共识别 5 种类型: “尖端电晕放电”、“绝缘类放电”、“金属微粒放电”、“悬浮电极放电”、以及“干扰”。该模型平均识别正确率为 88.9%。其中微粒放电的识别率较低, 大部分微粒放电被错误识别为绝缘类放电, 原因在于现场检测获取的微粒放电类型样本集数量太少, 导致数据集不平衡性高。其他 4 类识别效果较好, 均达到 85% 的识别率, 其中尖端电晕放电类型识别正确率为 100%。

### 3.3 传统分类模型对比分析

将本文提出的模型与传统分类模型进行了对比, 用于判断本文模型的识别效果。对比模型包括基于统计特征的支持向量机(SVM)、反向传播神经网络(BPNN)<sup>[21-22]</sup>。支持向量机选择径向基函数作为核函数, 参数为 0.01, 惩罚因子为 1200。反向传播神经网络迭代次数为 4000 次, 学习速率为 0.002。

表 5、表 6 分别表示 2 种模型对应的混淆矩阵。基于统计特征的支持向量机识别正确率为 70%, 反向传播神经网络识别正确率为 67.2%。支持向量机模型对电晕放电与绝缘类放电识别效果较好, 微粒放电均识别错误。对于反向传播神经网络, 尖端电晕识别效果与卷积神经网络相当, 但其他缺陷类型识别正确率均低于 75%。

图 8 表示了本文所用模型相比传统模型在各类缺陷的识别率增减情况。对比看出一维卷积神经网络

表 5 支持向量机局部放电模式识别混淆矩阵 Tab. 5 Confusion matrix of partial discharge pattern recognition by SVM %					
混淆情况	输出电晕	输出干扰	输出绝缘类	输出微粒	输出悬浮
尖端电晕	86.7	10	3.3	0	0
干扰	4.2	70.8	12.5	0	12.5
绝缘类放电	0	13	82	2	3
微粒放电	0	80	20	0	0
悬浮电位	0	31	10	0	59

表 6 反向传播神经网络局部放电模式识别混淆矩阵 Tab. 6 Confusion matrix of partial discharge pattern recognition by BPNN %					
混淆情况	输出电晕	输出干扰	输出绝缘类	输出微粒	输出悬浮
尖端电晕	96.7	3.3	0	0	0
干扰	13.3	63.3	4.2	0	19.2
绝缘类放电	0	17	71	3	9
微粒放电	0	70	20	10	0
悬浮电位	4	23	8	0	65




图 8 一维卷积神经网络各类识别准确率提高值  
Fig. 8 Increased value of pattern recognition accuracy rate by 1-D CNN

络在尖端电晕、干扰、金属微粒以及悬浮放电缺陷类型的识别率均明显高于基于统计特征的支持向量机, 识别率提升超过 10%。反向传播神经网络与一维卷积神经网络在尖端电晕缺陷识别效果相差较小, 其他 4 类均有较大的识别率提高。整体说明一维卷积神经网络在识别局放时域波形图像时优于支持向量机、反向传播神经网络模型。

### 3.4 识别准确率与复杂度分析

卷积神经网络的时间复杂度对应模型的运算次数, 决定了网络模型的训练与测试时间。对于卷积层的时间复杂度, 计算公式为

$$O(\sum_{l=1}^d n_{l-1} \cdot s_l^2 \cdot n_l \cdot m_l^2) \quad (12)$$

式中:  $l$  表示第  $l$  个卷积层;  $d$  表示卷积层深度;  $n_l$  表示第  $l$  层通道数;  $s_l$  表示卷积核边长;  $m_l$  表示输出特征图边长;  $s^2$  代表卷积核面积;  $m^2$  代表输出特征图面积。

针对一维卷积神经网络特性, 公式更新如下:

$$O(\sum_{l=1}^d n_{l-1} \cdot s_l \cdot n_l \cdot m_l) \quad (13)$$



在限定时间复杂度的情况下,网络结构的深度、特征通道数、卷积核大小等参数均对结果有影响,其中网络深度影响效果最明显<sup>[23]</sup>。对相同时间复杂度的一维卷积神经网络和二维卷积神经网络,控制特征通道数、卷积核面积不变,网络迭代次数与学习速率参数设置相同,比较网络识别率。

网络输入均为预处理得到的 $1 \times 784$ 尺寸的时域波形图像,二维卷积神经网络由于网络特性,将输入转换为 $28 \times 28$ 尺寸图像。2种网络的复杂度均为28000 FLOPS,具体网络结构与结果如表7所示。

表7 相同时间复杂度下一维卷积神经网络与二维卷积神经网络模式识别效果情况  
Tab. 7 Pattern recognition between 1-D CNN and 2-D CNN under same time complexity

结构层	1-D CNN	2-D CNN
输入层	$1 \times 784 \times 1$	$28 \times 28 \times 1$
卷积层1	$1 \times 9$	$3 \times 3$
池化层2	$1 \times 4$	$2 \times 2$
卷积层3	$1 \times 9$	$3 \times 3$
池化层4	$1 \times 4$	$2 \times 2$
全连接层	$1 \times 1024$	$1 \times 1024$
识别准确率/%	83.61	79.72

结果表明,对于局部放电时域波形图像,时间复杂度相同的情况下,控制其他特性不变,一维卷积神经网络更能表达脉冲电压的一维信息,适用于时域波形。2种网络如果达到相同的识别率,一维卷积神经网络时间复杂度将低于二维卷积神经网络,能够降低运算时间,更适应于工程实际应用。

## 4 结论

在大数据技术的推广应用中,来自变电站现场的非结构化局部放电图像数据大量存在。针对局部放电时域波形图像,本文提出一种基于一维卷积神经网络的模式识别方法,得到以下结论:

1) 本文提出的方法可以对非结构化的局部放电时域波形图像进行放电类型识别,使用算法直接处理该类非结构化数据,简化了模式识别中的特征提取步骤,降低了实验复杂度,且具有较好的鲁棒性。该方法还适用于大数据平台积累的其他非结构化数据,对后续进行大数据挖掘工作,提升检测数据利用效率均有重要意义。

2) 对于局部放电时域波形图像,一维卷积神经网络保留了时域波形图像的一维特性,识别效果优于基于统计特征的支持向量机、反向传播神经网络,实验中识别率分别提高了18.9%与21.7%。

3) 一维卷积神经网络降低了网络模型的复杂度,通过在时间轴上进行卷积操作,适应于时域波

形图像分析,有利于模式识别性能的提高。

## 参考文献

- [1] Kreuger F H, Galski E, Krivda A. Classification of partial discharges[J]. IEEE Transactions on Electrical Insulation, 1993, 28(6): 917-931.
- [2] 唐志国, 唐铭泽, 李金忠, 等. 电气设备局部放电模式识别研究综述[J]. 高电压技术, 2017, 43(7): 2263-2277.  
Tang Zhiguo, Tang Mingze, Li Jinzhong, et al. Review on partial discharge pattern recognition of electrical equipment[J]. High Voltage Engineering, 2017, 43(7): 2263-2277(in Chinese).
- [3] 李军浩, 韩旭涛, 刘泽辉, 等. 电气设备局部放电检测技术述评[J]. 高电压技术, 2015, 41(8): 2583-2601.  
Li Junhao, Han Xutao, Liu Zehui, et al. Review on partial discharge measurement technology of electrical equipment[J]. High Voltage Engineering, 2015, 41(8): 2583-2601(in Chinese).
- [4] 赵煦, 刘晓航, 孟永鹏, 等. 采用小波包树能量矩阵奇异值分解的局部放电模式识别[J]. 西安交通大学学报, 2017, 51(8): 116-121.  
Zhao Xu, Liu Xiaohang, Meng Yongpeng, et al. Partial discharge pattern classification by singular value decomposition of wavelet packet energy features[J]. Journal of Xi'an Jiaotong University, 2017, 51(8): 116-121(in Chinese).
- [5] 杨丰源, 宋辉, 程宇, 等. 基于多分辨高阶奇异谱熵分析的局部放电信号特征提取[J]. 电网技术, 2016, 40(10): 3265-3271.  
Yang Fengyuan, Song Hui, Cheng Xu, et al. Partial discharge feature extraction based on multi-resolution analysis of higher-order singular spectrum entropy[J]. Power System Technology, 2016, 40(10): 3265-3271(in Chinese).
- [6] 律方成, 谢军, 李敏, 等. 局部放电稀疏分解模式识别方法[J]. 中国电机工程学报, 2016, 36(10): 2836-2845.  
Lü Fangcheng, Xie Jun, Li Min, et al. A partial discharge pattern recognition method based on sparse decomposition[J]. Proceedings of the CSEE, 2016, 36(10): 2836-2845(in Chinese).
- [7] 张晓星, 舒娜, 徐晓刚, 等. 基于三维谱图混沌特征的GIS局部放电识别[J]. 电工技术学报, 2015, 30(1): 249-254.  
Zhang Xiaoxing, Shu Na, Xu Xiaogang, et al. GIS partial discharge recognition based on chaos features of the three-dimensional spectra[J]. Transactions of China Electrotechnical Society, 2015, 30(1): 249-254(in Chinese).
- [8] 曹健, 魏星, 李海生, 等. 基于局部特征的图像分类方法[J]. 电子科技大学学报, 2017, 46(1): 69-74.  
Cao Jian, Wei Xing, Li Haisheng, et al. Image classification methods based on local features[J]. Journal of University of Electronic Science and Technology of China, 2017, 46(1): 69-74(in Chinese).
- [9] Hinton G E, Salakhutdinov R R. Reducing the dimensionality of data with neural networks[J]. Science, 2006, 313(5786): 504.
- [10] Hinton G E, Srivastava N, Krizhevsky A, et al. Improving neural networks by preventing co-adaptation of feature detectors[J]. Computer Science, 2012, 3(4): 212-223.
- [11] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. The Journal of Machine Learning Research, 2014, 15(1): 1929-1958.
- [12] Taigman Y, Yang M, Ranzato M, et al. DeepFace: closing the gap to human-level performance in face verification[C]//IEEE Conference on Computer Vision and Pattern Recognition, Ohio, Columbus, 2014: 1701-1708.
- [13] 常亮, 邓小明, 周明全, 等. 图像理解中的卷积神经网络[J]. 自动化学报, 2016, 42(9): 1300-1312.  
Chang Liang, Deng Xiaoming, Zhou Mingquan, et al. Convolutional

- neural networks in image understanding[J]. Acta Automatica Sinica, 2016, 42(9): 1300-1312(in Chinese).
- [14] Kiranyaz S, Ince T, Gabbouj M. Real-time patient-specific ECG classification by 1D convolutional neural networks[J]. IEEE Transactions on Biomedical Engineering, 2016, 63(3): 664-675.
- [15] 魏东, 龚庆武, 来文青, 等. 基于卷积神经网络的输电线路区内外故障判断及故障选相方法研究[J]. 中国电机工程学报, 2016, 36(s1): 21-28.
- Wei Dong, Gong Qingwu, Lai Wenqing, et al. Research on internal and external fault diagnosis and fault-selection of transmission line based on convolutional neural network[J]. Proceedings of the CSEE, 2016, 36(s1): 21-28(in Chinese).
- [16] Ince T, Kiranyaz S, Eren L, et al. Real-time motor fault detection by 1-D convolutional neural networks[J]. IEEE Transactions on Industrial Electronics, 2016, 63(11): 7067-7075.
- [17] Guo Y, Liu Y, Oerlemans A, et al. Deep learning for visual understanding: A review[J]. Neurocomputing, 2016(187): 27-48.
- [18] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(6): 1229-1251.
- Zhou Feiyan, Jin Linpeng, Dong Jun. Review of convolutional neural network[J]. Chinese Journal of Computers, 2017, 40(6): 1229-1251(in Chinese).
- [19] Nair V, Hinton G E. Rectified linear units improve restricted Boltzmann machines[C]//Proceedings of the 27th International Conference on Machine Learning, Haifa, Israel, 2010: 807-814.
- [20] Boureau Y L, Ponce J, LeCun Y. A theoretical analysis of feature pooling in visual recognition[C]//Proceedings of the 27th international conference on machine learning, Haifa, Israel, 2010: 111-118.
- [21] 代杰杰, 宋辉, 杨祎, 等. 基于油中气体分析的变压器故障诊断 ReLU-DBN 方法[J]. 电网技术, 2018, 42(2): 658-664.
- Dai Jiejie, Song Hui, Yang Yi, et al. Dissolved gas analysis of insulating oil for power transformer fault diagnosis based on ReLU-DBN[J]. Power System Technology, 2018, 42(2): 658-664(in Chinese).
- [22] 代杰杰, 宋辉, 杨祎, 等. 基于深度信念网络的变压器油中溶解气体浓度预测方法[J]. 电网技术, 2017, 41(8): 2737-2742.
- Dai Jiejie, Song Hui, Yang Yi, et al. Concentration prediction of dissolved gases in transformer oil based on deep belief networks [J]. Power System Technology, 2017, 41(8): 2737-2742(in Chinese).
- [23] K. He, J. Sun. Convolutional neural networks at constrained time cost [C]//IEEE Conference on Computer Vision and Pattern Recognition, Boston, MA, 2015: 5353-5360.



万晓琪

收稿日期: 2018-06-21。

作者简介:

万晓琪(1995), 女, 硕士研究生, 研究方向为输变电设备状态监测与智能化, E-mail: sin043@sjtu.edu.cn;

宋辉(1987), 男, 博士, 通信作者, 助理研究员, 研究方向为输变电设备状态监测与智能化, E-mail: songeos@163.com。

(责任编辑 马晓华)